

最优化问题解题步骤

1. 建模最优化问题

我们首先需要根据题目的描述对于问题 (\mathcal{P}) 进行数学建模。包括问题中提供的任何信息。确定

- (1) 我们想要最大化或最小化目标函数，并将其统一转换成最小化问题；
- (2) 为目标方程中的变量依照题意添加约束，统一标准化为小于等于约束；
- (3) 如果可以，结合图形更加直观。

2. 确定目标函数的定义域 Ω

目标函数的定义域 Ω 的封闭性、有无界性、是否非空 和 凹凸性：必须是一个封闭(closed)的、有界的(bounded) 非空(non-empty) 凸区间(convex interval)（即两端都有端点并包含这些端点的区间，且区间中任意两点的连线上的所有点都属于这个区间）

3. 判断目标函数在定义域 Ω 上的极值情况

- 存在性(existence): 一阶偏导(梯度) ∇ 检验，评估目标函数在定义域 Ω 中的一阶偏导，简单判断目标函数的极值情况。例如：

$$\begin{aligned} f(x_1, x_2, x_3) &\Rightarrow f(z, z, z) \xrightarrow{z \rightarrow \infty} f \rightarrow \infty \text{ 无全局最大值,} \\ f(x_1, x_2, x_3) &\Rightarrow f(z, z, z) \xrightarrow{z \rightarrow -\infty} f \rightarrow -\infty \text{ 无全局最小值} \end{aligned}$$

- 唯一性(unicité): 二阶偏导(梯度) ∇^2 检验，要求：定义域 Ω 中必须只有一个极值。测试：求目标函数的二阶偏导，并在临界数处对其进行评估。如果该值为 < 0 ，则临界数表示严格极大值(strict maximum)。如果该值为 > 0 ，则临界数表示严格极小值(strict minimum)。

4. 构造拉格朗日乘数法或KKT

下略。

范数

是数学中的一种基本概念。在泛函分析中，它定义在赋范线性空间中，并满足一定的条件，即 ①非负性；②齐次性；③三角不等式。它常常被用来度量某个向量空间（或矩阵）中的每个向量的长度或大小。

- l_1 范数：

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

- l_2 范数：

$$\|x\|_2 = \sqrt{x^T x} = \sqrt{\sum_{i=1}^n x_i^2}$$

- l_∞ 范数：

$$\|x\|_{\infty} = \max\{|x_i| : i \in 1, 2, \dots, n\}$$

■ l_p 范数 :

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p\right)^{\frac{1}{p}}, p \in [1, \infty)$$

凸集

凸集 (Convex set)

给定非空集合 $F \subseteq \mathbb{R}^n$, 如果 $\forall x, y \in F, \alpha \in [0, 1]$ 都有 $\alpha x + (1 - \alpha)y \in F$, 那么我们就称这个 F 为 \mathbb{R}^n 中的一个凸集, 即集合中的任意两点的连线仍然属于该集合。

凸组合 (Convex combination)

x^1, x^2, \dots, x^k 的凸组合:

$$\lambda_1 x^1 + \lambda_2 x^2 + \dots + \lambda_k x^k$$

其中, $\lambda_1, \lambda_2, \dots, \lambda_k \geq 0, \sum_{i=1}^k \lambda_i = 1$

黑塞矩阵 (Hessian)

在之前的学习中我们已经知道, 一阶导数, 也就是目标函数的梯度, 反映了函数值随着自变量 x 变化的速率情况。所谓二阶导数, 就是在一阶导数的基础上再求导数, 反映了一阶导数的变化情况。

例如对于二次型函数 $f(x) = x^2$, 它的一阶导数就是 $\frac{df(x)}{dx} = 2x$, 二阶导数为 $\frac{d^2 f(x)}{dx^2} = 2$

将其推广, 对于一般的多元函数 $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$, 对其求一阶偏导数 (partial), 一阶偏导为向量称作梯度 (gradient):

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix}$$

我们再对一阶导数 $\frac{\partial f(x)}{\partial x}$ 对于 x_i 求偏导, 我们可以得到

$$\nabla\left(\frac{\partial f}{\partial x_i}\right) = \nabla^2 f(x) = \begin{bmatrix} \frac{\partial}{\partial x_1} \frac{\partial f}{\partial x_1} & \frac{\partial}{\partial x_2} \frac{\partial f}{\partial x_1} & \cdots & \frac{\partial}{\partial x_n} \frac{\partial f}{\partial x_1} \\ \frac{\partial}{\partial x_1} \frac{\partial f}{\partial x_2} & \frac{\partial}{\partial x_2} \frac{\partial f}{\partial x_2} & \cdots & \frac{\partial}{\partial x_n} \frac{\partial f}{\partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial}{\partial x_1} \frac{\partial f}{\partial x_n} & \frac{\partial}{\partial x_2} \frac{\partial f}{\partial x_n} & \cdots & \frac{\partial}{\partial x_n} \frac{\partial f}{\partial x_n} \end{bmatrix} \leftarrow \text{Hessian Matrix}$$

黑塞矩阵是对梯度再求一次偏导, 所以它是 $n \times n$ 的方阵, 满足对称性 $\mathcal{H}_{ij} = \mathcal{H}_{ji}$

例: 对于 $f(x, y) = 5x + 8y + xy - x^2 - 2y^2$

$$\nabla f(x, y) = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 5 - 2x + y \\ 8 + x - 4y \end{bmatrix}$$

$$\mathcal{H}(x) = \begin{bmatrix} 2 & 1 \\ 1 & -4 \end{bmatrix}$$

对于二次函数，黑塞矩阵为常数矩阵。

黑塞矩阵的意义

如果一个函数的黑塞矩阵是正定 (positive definite) 的，即特征值大于 0，也即目标函数在所有可行方向 d 上的二阶导数都大于 0。我们就可以得出 $f(x)$ 是一个严格的凸函数，其极值就是极小值，而且也是全局的最小值。

矩阵的正定

正定矩阵首先是一个对称阵。以下我们介绍一种判断矩阵是否正定的方法，Sylvester's Criterion:

Sylvester's Criterion

各阶行列式（顺序主子式）都大于0 \Rightarrow 矩阵正定 $\succ 0$

$$\begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix} \Rightarrow |2| > 0 \quad \begin{vmatrix} 2 & -1 \\ -1 & 2 \end{vmatrix} > 0 \quad \begin{vmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{vmatrix} > 0$$

无约束优化问题的最优性条件

无约束优化问题： $\min f(x)$

最优解的定义：

- 局部最优解：对于一个解 \bar{x} ，在 \bar{x} 的临域空间 $N_s(\bar{x})$ 内 $f(\bar{x})$ 的值是最大或最小的。

$$\forall x \in N_s(\bar{x}), f(x) \geq f(\bar{x}) \text{ 或 } f(x) \leq f(\bar{x})$$

- 全局最优解：对于一个解 \bar{x} ，在任意n维空间 \mathbb{R}^n 内 $f(\bar{x})$ 的值是最大或最小的。

$$\forall x \in \mathbb{R}^n, f(x) \geq f(\bar{x}) \text{ 或 } f(x) \leq f(\bar{x})$$

- 严格局部最优解：对于一个解 \bar{x} ，在 \bar{x} 的临域空间 $N_s(\bar{x})$ 内 $f(\bar{x})$ 的值是严格最大或最小的（不包含等于情况）。

$$\forall x \in N_s(\bar{x}), f(x) > f(\bar{x}) \text{ 或 } f(x) < f(\bar{x})$$

- 严格全局最优解：对于一个解 \bar{x} ，在任意n维空间 \mathbb{R}^n 内 $f(\bar{x})$ 的值是严格最大或最小的（不包含等于情况）。

$$\forall x \in \mathbb{R}^n, f(x) > f(\bar{x}) \text{ 或 } f(x) < f(\bar{x})$$

最优性条件

考虑无约束优化问题： $\min f(x)$

- 必要条件：若 x^* 是最优解，则 x^* 有如下性质：

- (1) $\nabla f(x^*) = 0$ 目标函数在 x^* 的位置时梯度为零
- (2) $\nabla^2 f(x^*) \succeq 0$ 目标函数在 x^* 的位置时黑塞矩阵是半正定的

- 充分条件：

若 $\nabla f(x^*) = 0, \nabla^2 f(x^*) \succ 0 \Rightarrow$ 则 x^* 是严格最优的

无约束优化：线搜索 和 信赖域

考虑无约束优化问题： $\min f(x)$

迭代下降算法的描述：

给定一个初始点 x_0 ，我们可以判断 x_0 是否是我们需要找的点，如果不是，我们要产生点列 $\{x_k\}_{k=1}^\infty$ ，并且满足 $f(x_{k+1}) < f(x_k)$ “下一个点的函数值比当前点的函数值小”。我们有两种策略：线搜索 (Line search) 和 信赖域 (Trust region)

线搜索方法

算法描述

1. 给定初始点 x_0
2. 判断 x_0 是否满足【终止条件】；是，则终止
3. 当前点为 x_k ，首先找到【下降方向 d_k 】（从这个点出发，有一段步长的距离，目标函数值会减小的方向）
4. 确定【步长 $\alpha_k > 0$ 】，使得 $f(x_k + \alpha_k d_k) < f(x_k)$
5. 我们就得到了下一个点 $x_{k+1} := x_k + \alpha_k d_k$ ；转第 2 步

- 终止条件： $\|\nabla f(x_k)\|_2 \leq \mathcal{E}$ ，其中 \mathcal{E} 是一个很小的正整数，意味着当梯度趋近于 0
- 下降方向 d_k 的选择：最速下降、共轭梯度等
- 步长 α_k 的选择：我们令 $\phi(\alpha) := f(x_k + \alpha d_k)$ ，步长 $\alpha_k = \min_{\alpha \geq 0} \phi(\alpha)$
- 算法结束后会给我们一个点列 $\{x_k\}$ ，我们需要关心点列的收敛性和收敛速度

信赖域方法

1. 当前点为 x_k ，首先决定“活动范围 Δ ” $\|d\|_2 \leq \Delta$
2. 再决定“活动方向”

无约束优化：最速下降

收敛速度

设当前点列 $\{x_k\}$ 收敛到 x^* ，若存在极限

$$\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|_2}{\|x_k - x^*\|_2} = \beta$$

- 当 $0 < \beta < 1$ 时，则称点列 $\{x_k\}$ 为线性收敛
- 当 $\beta = 0$ 时，则称点列 $\{x_k\}$ 为超线性收敛

若存在某个 $p \geq 1$ ，有

$$\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|_2}{\|x_k - x^*\|_2^p} = \beta < +\infty$$

则称点列 $\{x_k\}$ 为 p 阶收敛

- 当 $p > 1$ 时， p 阶收敛必为超线性收敛

最速下降法

也叫做梯度下降法。【基本思想】是选择 x_k 处的负梯度方向作为搜索方向，即 $d_k = -\nabla f(x_k)$

- 优点：简单直观；收敛；搜索方向只需计算 $-\nabla f(x_k)$
- 缺点：收敛速度慢（线性搜索）；Zigzag现象（路径是“之”字形）；不具备“在有限步内求得凸二次函数最优解”的特性

约束优化：KKT 条件

一阶必要条件：最优解 \rightarrow KKT 点

假设 x^* 是问题 \mathcal{P} 的局部最优解，且 x^* 某处的约束规范 (constraint qualification) 成立，则存在 λ, μ 使得

$$\begin{aligned} & \min_{x \in \mathbb{R}^2} f(x) \\ & s.t. \quad \forall i \in \{1, 2, \dots, l\} : h_i(x) = 0 \quad \text{且} \quad \forall j \in \{1, 2, \dots, m\} : g_j(x) \leq 0 \\ & \text{可行集 } S(\mathcal{E}) = \{x \mid \text{满足 } s.t.\} \end{aligned}$$

1.
$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{i=1}^l \mu_i \nabla h_i(x^*) = 0$$
2. $\forall i \in \{1, 2, \dots, m\} : \lambda_i \geq 0$
3. $\forall i \in \{1, 2, \dots, m\} : g_i(x^*) \leq 0$
4. $\forall i \in \{1, 2, \dots, m\} : h_i(x^*) = 0$
5. $\forall i \in \{1, 2, \dots, m\} : \lambda_i g_i(x^*) = 0$

二阶充分条件： \mathcal{KKT} 点 \rightarrow 最优解

假设 x^* 满足上述的 \mathcal{KKT} 条件，我们定义一个函数 $\mathcal{L}(x) = f(x) + \sum \mu_i h_i(x) + \sum \lambda_i g_i(x)$ ，可知：

1. $\nabla_x \mathcal{L}(x^*) = 0$ \mathcal{KKT} 条件中的第 1 条
2. $\mathcal{L}(x^*) = f(x^*) + \sum \mu_i h_i(x^*) + \sum \lambda_i g_i(x^*) = f(x^*) + 0 + 0 \Rightarrow \mathcal{L}(x^*) = f(x^*)$
3. $\forall x \in S(\mathcal{E}), \mathcal{L}(x) \leq f(x)$

有以下结论：

- 由 2, 3 可知，若 x^* 是 $\mathcal{L}(x)$ 的最优解，则 x^* 也是 \mathcal{P} 的最优解： $f(x^*) = \mathcal{L}(x^*) \leq \mathcal{L}(x) \leq f(x)$
- 若 $\nabla_{xx} \mathcal{L}(x^*) \succeq 0, \forall x \in S(\mathcal{E})$ ，则 x^* 是 \mathcal{P} 的全局最优解
- 若 $\nabla_{xx} \mathcal{L}(x^*) \succeq 0, \forall x \in \{S(\mathcal{E}) \cap_{\text{临域}} N_S(x^*)\}$ ，则 x^* 是 \mathcal{P} 的局部最优解
- 若 $\nabla_{xx} \mathcal{L}(x^*) \succ 0$ ，则 x^* 是 \mathcal{P} 的严格局部最优解

约束优化：对偶理论

考虑如下一般形式的约束优化问题：

$$\begin{aligned} (\mathcal{P}) : & \min_{x \in \mathbb{R}^2} f(x) \\ \text{s.t.} \quad & \begin{cases} h_i(x) = 0, \forall i \in \{1, 2, \dots, l\} \\ g_j(x) \leq 0, \forall j \in \{1, 2, \dots, m\} \\ x \in X \end{cases} \end{aligned}$$

可行集 $S(\mathcal{E}) = \{x \in X | \text{满足 s.t.}\}$

其中 X 是“集合约束”，如果：

1. $X = \mathbb{R}^n$ 所研究的问题 \mathcal{P} 就是在 n 维实数域上的连续优化问题，就可以运用以上知识
2. $X = \mathbb{Z}_+^n$ 所研究的问题 \mathcal{P} 就是在 n 维整数（或非负整数）域上的连续优化问题，就可以运用以上知识
3. $X = \{0, 1\}^n$ 所研究的问题 \mathcal{P} 就是在 n 维 **0-1** 集合上的离散整数优化问题

对偶问题的意义

$$\text{原问题 } (\mathcal{P}) \xrightarrow{\text{构建}} \text{对偶问题 } (\mathcal{D})$$

1. 如果原问题 (\mathcal{P}) 是非凸问题，我们很难求解这一类 NP-hard 问题，我们就可以构造一个和原问题 (\mathcal{P}) 的关系紧密又简单的对偶问题 (\mathcal{D}) 来求解；
2. 在线性规划问题中的对偶问题；
3. 鲁棒优化，锥优化

拉格朗日对偶问题

$$\begin{aligned} (\mathcal{P}) : & \min_{x \in \mathbb{R}^2} f(x) \\ \text{s.t.} \quad & \begin{cases} h_i(x) = 0, \forall i \in \{1, 2, \dots, l\} \\ g_j(x) \leq 0, \forall j \in \{1, 2, \dots, m\} \\ x \in X \end{cases} \end{aligned}$$

$$\text{可行集 } S(\mathcal{E}) = \{x \in X \mid \text{满足 s.t.}\}$$

我们引入拉格朗日函数：

$$\mathcal{L}(x, \lambda, \mu) = f(x) + \sum_{i=1}^l \mu_i h_i(x) + \sum_{i=1}^m \lambda_i g_i(x)$$

此时我们对拉格朗日函数 \mathcal{L} 求最小值，得到拉格朗日对偶函数 (dual function)：

$$\begin{aligned} d(\lambda, \mu) &= \min_{x \in X} (\mathcal{L}(x, \lambda, \mu)) = \min_{x \in X} \{f(x) + \sum_{i=1}^l \mu_i h_i(x) + \sum_{i=1}^m \lambda_i g_i(x)\} \\ &\leq \min_{x \in S(\mathcal{E})} \{f(x) + \sum_{i=1}^l \mu_i h_i(x) + \sum_{i=1}^m \lambda_i g_i(x)\} \\ &\leq \min_{x \in S(\mathcal{E})} \{f(x)\} \end{aligned}$$

- 对于 $\forall (\lambda, \mu), \lambda \geq 0$ 必有 $d(\lambda, \mu) \leq v(\mathcal{P})$ ，即 $d(\lambda, \mu)$ 是 $v(\mathcal{P})$ 的下界，所以我们要找出 $d(\lambda, \mu)$ 的【最大值】

此时我们就可以给出拉格朗日问题的对偶问题 (\mathcal{D})：

$$\begin{aligned} (\mathcal{D}) : & \max d(\lambda, \mu) \\ \text{s.t.} \quad & \lambda_i \geq 0, \forall i \in \{1, 2, \dots, m\} \end{aligned}$$

写成以下形式：

$$(\mathcal{D}) : \max_{\lambda \geq 0} \min_{x \in X} (\mathcal{L}(x, \lambda, \mu)) \xrightarrow{\text{交换}} \min_{x \in X} \max_{\lambda \geq 0} (\mathcal{L}(x, \lambda, \mu))$$

经过推导，问题 (\mathcal{D}) 可转化成原问题 (\mathcal{P})：

$$\begin{aligned} (\mathcal{P}) : & \min_{x \in \mathbb{R}^2} f(x) \\ \text{s.t.} \quad & \begin{cases} h_i(x) = 0, \forall i \in \{1, 2, \dots, l\} \\ g_j(x) \leq 0, \forall j \in \{1, 2, \dots, m\} \\ x \in X \end{cases} \end{aligned}$$

弱对偶定理

在之前拉格朗日对偶问题中，“对于 $\forall (\lambda, \mu), \lambda \geq 0$ 必有 $d(\lambda, \mu) \leq v(\mathcal{P})$ ，即 $d(\lambda, \mu)$ 是 $v(\mathcal{P})$ 的下界，所以我们要找出 $d(\lambda, \mu)$ 的最大值”。我们可以推导到一般：

- 设 $v(\mathcal{P})$ 是原问题 (\mathcal{P}) 的最优值， $v(\mathcal{D})$ 是对偶问题 (\mathcal{D}) 的最优值，则 $v(\mathcal{D}) \leq v(\mathcal{P})$

推论：假设 $\bar{x} \in S(\mathcal{E})$ ， $(\bar{\lambda}, \bar{\mu}), \bar{\lambda} \geq 0$ 且 $d(\bar{\lambda}, \bar{\mu}) = f(\bar{x})$ ，则 $v(\mathcal{P}) = v(\mathcal{D})$ 且 $\bar{x}, (\bar{\lambda}, \bar{\mu})$ 是 $v(\mathcal{P})$ 和 $v(\mathcal{D})$ 的最优解